



UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO
BACHARELADO EM MATEMÁTICA APLICADA E COMPUTAÇÃO
CIENTÍFICA

VILENO CUNHA CAVALCANTE

INFLUÊNCIA DO USO DE BUSCA LINEAR EXATA NA
CONVERGÊNCIA DE MÉTODOS ACELERADOS DE GRADIENTE
PROXIMAL

SÃO CARLOS - SP
2025

VILENO CUNHA CAVALCANTE

**INFLUÊNCIA DO USO DE BUSCA LINEAR EXATA NA
CONVERGÊNCIA DE MÉTODOS ACELERADOS DE GRADIENTE
PROXIMAL**

Relatório parcial do Programa Unificado de Bolsas (PUB) apresentado a Pró-Reitoria de Pesquisa e Inovação (PRPI), como parte das exigências para a conclusão da Iniciação Científica em Influência do Uso de Busca Linear Exata na Convergência de Métodos Acelerados de Gradiente Proximal, sob orientação da Prof. Dr. Elias Salomão Helou Neto.

**SÃO CARLOS - SP
2025**

Sumário

1	Introdução	1
2	Justificativa	3
2.1	Tomografia computadorizada	3
2.2	Motivação para o estudo proposto	4
3	Materiais e Métodos	5
4	Objetivos	6
4.1	Objetivos gerais	6
4.2	Objetivos específicos	6
5	Método de Otimização	7
5.1	Algoritmo FISTA	7
5.2	Estratégias usuais de escolha do tamanho de passo	7
5.3	Estratégia proposta: busca linear exata	8
6	Implementação e Experimentos Numéricos	8
6.1	Descrição dos dados e configuração experimental	8
6.2	Métricas de avaliação	9
6.3	Resultados obtidos	9
6.3.1	Análise do ganho de velocidade de convergência	9
6.3.2	Análise custo/benefício em tempo de computação	13
6.3.3	Aplicações	14
7	Discussão e Conclusões	16

Lista de Figuras

1	Evolução de $F(x)$ ao longo das iterações para cada método	9
2	Caption	10
3	Erros de relativos de x^k	12
4	Caption	13
5	Caption	15

Lista de Tabelas

1	Comparação dos valores mínimos obtidos com 100 iterações por diferentes métodos para cada escolha de passo.	11
2	Tempo e número de iterações por método	13

1 Introdução

Praticamente todos problemas em diversas áreas da ciência e da engenharia utilizam métodos matemáticos para serem modelados e resolvidos. Em particular, grande parte desses problemas pode ser formulados como a minimização de funções convexas e a esses problemas dar-se o nome de otimização. De maneira geral, um problema de otimização consiste em determinar os valores de um conjunto de variáveis de decisão que minimizam (ou maximizam) uma função objetivo, sujeita a restrições que modelam limitações físicas, econômicas ou operacionais do sistema em estudo.

Existem muitas classificações possíveis para um problema de otimização, que podem ser caracterizadas de acordo com o valor que suas variáveis de decisão podem assumir, e quanto à natureza de sua função objetivo e de suas restrições. Neste trabalho, abordamos os problemas de otimização não linear onde (aqui explica o que um problema de otimização não linear), mais especificamente problemas de otimização convexa composta da forma

$$\min_{x \in \mathbb{R}^n} F(x) = f(x) + g(x),$$

onde f é convexa diferenciável com gradiente Lipschitz-contínuo e g é convexa. Problemas como esse aparecem com frequência em matemática aplicada, aprendizado de máquina e processamento de sinais ?. Um caso de amplo interesse é quando temos problemas de reconstrução de imagens através da minimização de funções com a seguinte forma

$$\min_{x \in \mathbb{R}^n} \frac{1}{2} \|Ax - b\|_2^2 + g(x), \quad (1)$$

onde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e prox-amigável. Por prox-amigável, queremos dizer que o operador proximal de λg , para $\lambda \in \mathbb{R}_+$, é calculável em um tempo de computação razoável. A definição do operador proximal $\text{prox}_{\lambda g}(x)$ de λg em x é dado por

$$\text{prox}_{\lambda g}(x) := \arg \min_{y \in \mathbb{R}^n} \frac{1}{2} \|y - x\|_2^2 + \lambda g(y). \quad (2)$$

Para essa classe de problemas, os métodos de gradiente proximal constituem uma abordagem eficiente e amplamente utilizada. Os métodos acelerados de gradiente proximal, inspirados na aceleração de Nesterov, alcançam a taxa ótima de convergência $\mathcal{O}(1/k^2)$ no caso convexo, superando a taxa $\mathcal{O}(1/k)$ dos métodos proximais clássicos. Entretanto, seu desempenho depende criticamente da escolha do tamanho de passo, usualmente determinado a partir da constante de Lipschitz do gradiente de f , que nem sempre é conhecida ou estimada de forma adequada.

Uma alternativa é empregar estratégias adaptativas, como a busca linear. Em particular, a busca linear exata determina o tamanho de passo ótimo ao longo da direção escolhida, podendo potencialmente melhorar o desempenho prático do método. No en-

tanto, sua interação com o mecanismo de aceleração ainda demanda análise cuidadosa, pois pode afetar propriedades como estabilidade e taxa de convergência.

Neste trabalho, investigamos a influência do uso de busca linear exata na convergência de métodos acelerados de gradiente proximal. Analisamos sob quais condições a estratégia preserva as garantias teóricas conhecidas, se pode melhorar o comportamento prático do algoritmo e como impacta a dinâmica iterativa do processo de otimização. Resultados teóricos são acompanhados de experimentos numéricos que ilustram o efeito da busca linear exata no desempenho do método.

2 Justificativa

Em problemas de reconstrução de imagens, o número n de variáveis corresponde ao número de *pixels* da imagem e, portanto, pode ser extremamente grande, frequentemente da ordem de centenas de milhares ou até mesmo milhões. Problemas da forma (1) surgem em diversas aplicações de processamento de imagens, como tomografia computadorizada ????, remoção de ruído em imagens ??? e restauração de imagens desfocadas e degradadas por ruído ???.

De maneira geral, esse tipo de modelo aparece naturalmente no contexto da regularização variacional de problemas inversos lineares mal condicionados ?. Em tomografia computadorizada, por exemplo, o problema de reconstrução pode ser formulado como um sistema linear de grande dimensão, frequentemente envolvendo matrizes muito grandes e esparsas.

2.1 Tomografia computadorizada

Deixando de lado o desenvolvimento de detalhes técnicos da física subjacente, a situação em um tomógrafo leva a um modelo baseado na transformada de Radon ??? $\mathcal{R}[f]$ de $f : \mathbb{R}^2 \rightarrow \mathbb{R}$, definida através de

$$\mathcal{R}[f](\theta, t) := \int_{\mathbb{R}} f \left(t \begin{pmatrix} \cos \theta \\ \sin \theta \end{pmatrix} + s \begin{pmatrix} -\sin \theta \\ \cos \theta \end{pmatrix} \right) ds.$$

Veja a Figura 1 para uma ilustração.

A incógnita é a função f , ao passo que os dados obtidos são os valores da transformada de Radon $\mathcal{R}[f]$. Uma vez que o tempo de coleta de dados é limitado e que na prática a função solução é buscada em um espaço de dimensão finita, o problema pode ser reduzido à solução (aproximada) de um sistema de equações lineares

$$Rx \approx r,$$

onde $R \in \mathbb{R}^{m \times n}$ é uma matriz obtida a partir da discretização da transformada de Radon, que depende da base utilizada para descrever o espaço de funções e das condições geométricas de aquisição, $x \in \mathbb{R}^n$ é o vetor desconhecido de coeficientes da combinação linear de elementos da base que resulta na solução do problema (i.e., a solução é

$$f = x_1 f_1 + x_2 f_2 + \cdots + x_n f_n,$$

onde $\{f_1, f_2, \dots, f_n\}$ é a base para o espaço de funções onde a solução é buscada) e r é o vetor de dados coletados (sempre aproximado pois há erros sistemáticos de modelagem e ruído na aquisição dos dados).

2.2 Motivação para o estudo proposto

Uma vez que, graças à natureza da transformada de Radon, a matriz R sempre é mal condicionada e o lado direito r inevitavelmente contém ruído, a solução aproximada deve ser estabilizada através do uso de um termo de suavização, de modo que o modelo a ser resolvido possua a forma

$$\min_x f(Rx, r) + \gamma g(x),$$

onde $f : \mathbb{R}^m \times \mathbb{R}^m \rightarrow \mathbb{R}$ é uma função que força a proximidade entre Rx e r , $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é uma função que força a suavidade da imagem resultante e $\gamma \in \mathbb{R}_+$ é um parâmetro que controla a suavidade imposta na solução do problema. Algoritmos de ε -subgradientes foram utilizados com sucesso em ? e algoritmos acelerados de primeira ordem em ?? para resolver modelos úteis da forma acima. Nenhum dos trabalhos mencionados leva em consideração a forma específica de quadrados mínimos regularizados que possui (1), portanto, esperamos que as técnicas a serem estudadas no presente projeto sejam ainda mais bem sucedidas nesta aplicação.

3 Materiais e Métodos

A execução do presente projeto utilizará computadores comuns e *software* de código livre cuja disponibilidade é ampla e que são facilmente acessíveis. Nos dias de hoje, rotinas numéricas eficientes são facilmente utilizadas através de suas interfaces de programação para linguagens de alto nível, mesmo quando tais rotinas são implementadas em linguagens mais ineficientes. Em particular, a linguagem Python reúne numerosas bibliotecas úteis no nosso contexto e, por este motivo, escolhemos esta linguagem para a execução da parte computacional do nosso projeto.

Por exemplo, para a computação de produtos matriz-vetor da forma Ax ou $A^T y$, onde A é a discretização da Transformada de Radon, temos as bibliotecas ASTRA ou a desenvolvida pelo orientador ¹, ambas com suporte a GPU e com interfaces para Python. Para outras modalidades de reconstrução como recuperação de imagens desfocadas, podemos usar as ferramentas implementadas eficientemente no pacote `scipy.signal`.

Para a parcela de regularização, iremos utilizar uma opção que é apropriada para o problema de reconstrução de imagens:

$$g(x) = \gamma \|Hx\|_1,$$

onde $\gamma \geq 0$ é o parâmetro de regularização e H é uma transformada *wavelet* (que é ortogonal, auto-adjunta e computável eficientemente). Para esta regularização, o operador proximal de λg tem a forma fechada

$$\text{prox}_{\lambda g}(x) = H^T S_{\gamma\lambda}(Hx),$$

onde $S_{\gamma\lambda}$ é o operador de *soft-thresholding*, dado por

$$(S_{\alpha}(y))_i = \begin{cases} y_i + \alpha, & \text{se } y_i \leq -\alpha, \\ 0, & \text{se } y_i \in (-\alpha, \alpha), \\ y_i - \alpha, & \text{se } y_i \geq \alpha. \end{cases}$$

¹https://github.com/elias-helou/ray_tracing

4 Objetivos

4.1 Objetivos gerais

O objetivo do seguinte projeto de iniciação científica é estudar o que ocorre quando, para o caso especial (1), o tamanho de passo de máxima descida do método de gradiente proximal acelerado conhecido como FISTA ?? é escolhido através de busca direcional exata.

4.2 Objetivos específicos

- Analisar experimentalmente o ganho de velocidade de convergência em número de iterações com o uso do passo exato com regularização baseada na transformada *wavelet*.
- Avaliar o ganho de custo/benefício em tempo de computação entre o passo fixo e passo exato com regularização baseada na transformada *wavelet*.
- Aplicar o método para o caso de reconstrução de imagens com regularização baseada na transformada *wavelet*.

5 Método de Otimização

Ao resolver numericamente um problema de otimização matemática, o algoritmo a ser utilizado deve ser escolhido baseado em considerações acerca do problema em mãos. Durante o processo de escolha de tal algoritmo numérico, devemos levar em conta a categoria de problema sendo resolvido (linear, cônico de segunda ordem, convexo, suave, inteiro, contínuo, etc.) e da informação disponível, também conhecida como oráculo, a cada passo do método (valor funcional, gradientes, hessianas, funções substitutas, minimizadores de relaxações, etc.). Outros fatores importantes também influenciam a escolha do método, tais como ambiente e plataforma computacional, tempo de computação disponível, precisão numérica necessária ou desejada, dimensões do problema (número de variáveis e tamanho do conjunto de dados), dentre outros.

5.1 Algoritmo FISTA

Considere o problema

$$\min_{x \in \mathbb{R}^n} f(x) + g(x), \quad (3)$$

onde $f : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa e diferenciável e $g : \mathbb{R}^n \rightarrow \mathbb{R}$ é convexa.

Ademais, supomos que o gradiente de f é Lipschitz. Isto é, existe $L_f \geq 0$ tal que

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L_f \|x - y\|_2$$

e que o operador proximal de g , como definido em (2), pode ser calculado com relativa facilidade.

Para esta categoria de problemas, quando o número n de variáveis é muito grande, um algoritmo popular para aplicação é o FISTA ??:

$$\begin{aligned} y^{(k)} &= \text{prox}_{\lambda_k g} \left(x^{(k)} - \lambda_k \nabla f(x^{(k)}) \right) \\ t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2} \\ x^{(k+1)} &= y^{(k)} + \frac{t_k - 1}{t_{k+1}} \left(y^{(k)} - y^{(k-1)} \right). \end{aligned}$$

5.2 Estratégias usuais de escolha do tamanho de passo

Na formulação acima, o passo λ_k pode ser mantido fixo, desde que suficientemente pequeno, mas precisamente $\frac{1}{L}$, em que $L > 0$ é a constante de Lipschitz de $\nabla f(x)$, ou determinado através de uma busca direcional acoplada a um critério de descida suficiente.

5.3 Estratégia proposta: busca linear exata

Observe que FISTA foi desenvolvido para o caso mais geral (3), onde a busca direcional exata é impossível. Para o caso em que f é uma função quadrática da forma

$$f(x) = \frac{1}{2}x^T Ax - c^T x,$$

entretanto, o tamanho de passo que minimiza a função a partir de $x^{(k)}$ ao longo de uma direção de busca $d^{(k)} = \nabla f(x^{(k)})$ pode ser calculado com esforço computacional relativamente baixo através da fórmula

$$\lambda_k = \frac{(d^{(k)})^T d^{(k)}}{(d^{(k)})^T A d^{(k)}}$$

Em métodos para minimizar apenas a função quadrática f , o cálculo de $A d^{(k)}$ pode ser reaproveitado posteriormente ou vir de quantidades calculadas previamente.

6 Implementação e Experimentos Numéricos

6.1 Descrição dos dados e configuração experimental

Os experimentos computacionais foram realizados em um computador Intel[®] Core[™] i7-11800H - 8GB de RAM com frequência 2.30GHz com sistema operacional Windows 11 Pro versão 25H2. O modelo foi implementado em linguagem de programação Python versão 3.12.4 no ambiente de desenvolvimento Visual Studio Code versão 1.97.2. Foram utilizadas as bibliotecas NumPy, para operações matriciais e cálculos numéricos. Para a modalidade de reconstrução de imagem desfocadas, as operações de *convolução* A e sua adjunta A^T (*correlação*) foram ambas implementadas utilizando a biblioteca `scipy.signal`.

Neste experimento, usamos uma imagem bidimensional de dimensão 512×512 pixels monocromática de uma câmera, normalizada no intervalo padrão da biblioteca. Esta imagem está disponível na biblioteca `skimage-image`. E por fim; foi utilizado a `matplotlib`, para visualização das imagens e análise gráfica do comportamento dos métodos iterativos.

Como uma boa prática, antes da execução dos métodos iterativos, foi realizada uma verificação numérica da propriedade de adjuntividade entre os operadores A e A^T , verificando se a relação

$$\langle Ax, y \rangle = \langle x, A^T y \rangle$$

é satisfeita para vetores aleatórios x e y . Os resultados numéricos confirmaram a consistência da implementação dos operadores.

Aqui justificar a escolha dos parâmetros gamma e passo

6.2 Métricas de avaliação

A qualidade da reconstrução e o desempenho dos métodos iterativos foram avaliados a partir de diferentes métricas numéricas e visuais.

- O valor da função objetivo F foi monitorado ao longo das iterações para cada método.
- Além disso, foi considerado os erros relativos da imagem reconstruída e da função objetivo

$$e_x^k = \frac{|x^k - x^*|}{|x^*|} \quad \text{e} \quad e_F^k = \frac{|F(x^k) - F^*|}{|F^*|}$$

respectivamente, onde x^* denota a imagem original e F^* o melhor valor de f obtido pelo método dos gradientes conjugados ??.


6.3 Resultados obtidos

Analisaremos agora os resultados obtidos nos experimentos.

6.3.1 Análise do ganho de velocidade de convergência

O gráfico da Figura 1 apresenta a evolução do valor da função objetivo $F(x)$ ao longo de 100 iterações para diferentes métodos de otimização: Gradiente Descendente, Nesterov, ISTA, FISTA e Gradiente Conjugado, considerando diferentes estratégias de escolha do passo (fixo e exato).

Figura 1: Evolução de $F(x)$ ao longo das iterações para cada método




Observa-se inicialmente que todos os métodos apresentam comportamento convergente, uma vez que o valor da função objetivo diminui rapidamente nas primeiras iterações e

posteriormente se estabiliza próximo a um valor mínimo. Isso sugere que, independentemente do método ou da escolha de passo utilizada, as soluções encontradas tendem ao valor ótimo.

Embora todos os métodos apresentem comportamento convergente, podemos notar que a escolha do método e da estratégia de passo pode influenciar significativamente a qualidade da solução obtida e na velocidade de convergência após um número fixo de iterações. O menor valor da função objetivo foi obtido pelo método FISTA com passo exato, atingindo aproximadamente $F(x) \approx 101818.96$, enquanto o maior valor final observado ocorreu no método Gradiente Descendente com passo fixo igual a 0.1, com valor aproximado de $F(x) \approx 442505.48$.

Podemos notar ainda que alguns métodos, como Nesterov e FISTA, apresentam oscilações na convergência, o que pode ser observado de forma mais clara nos gráficos da Figura (2), que mostram a convergência de cada método para as diferentes escolhas de passo.

Figura 2: Caption



No método do Gradiente Descendente, percebe-se um comportamento monotonicamente decrescente da função objetivo para todas as escolhas de passo analisadas. No entanto, a velocidade de convergência depende fortemente do valor do passo. Para o passo fixo igual a 0.1, a redução da função objetivo ocorre de forma mais lenta, enquanto valores maiores de passo, como 0.5 e 1.0, apresentam convergência mais rápida. O uso do passo exato produz uma das reduções mais rápidas da função objetivo ao longo das

iterações, sendo o método que obteve o menor valor da função objetivo.

No caso do método de Nesterov, os resultados indicam um comportamento diferente. Para valores maiores de passo, o método apresenta oscilações nas primeiras iterações. Essas oscilações são particularmente visíveis quando se utiliza passo fixo de 0.1. Apesar disso, o método consegue estabilizar ao longo das iterações, convergindo posteriormente para valores próximos aos obtidos pelos demais métodos. Os métodos ISTA e FISTA apresentam comportamentos semelhantes, respectivamente, aos observados nos métodos do Gradiente Descendente e Nesterov.

A Tabela 1 apresenta os valores da função objetivo após 100 iterações para cada método considerado e para diferentes escolhas de tamanho de passo.

Tabela 1: Comparação dos valores mínimos obtidos com 100 iterações por diferentes métodos para cada escolha de passo.

Passo fixo $\lambda = 0.1$		Passo fixo $\lambda = 0.5$	
Método	Valor mínimo	Método	Valor mínimo
Gradiente	442835.2	Gradiente	164861.2
Nesterov	128402.9	Nesterov	108425.6
ISTA	258894.7	ISTA	137001.8
FISTA	116981.9	FISTA	103491.7
Grad. Conjugado	112492.3	Grad. Conjugado	112492.3

Passo fixo $\lambda = 1.0$		Passo exato	
Método	Valor mínimo	Método	Valor mínimo
Gradiente	136198.7	Gradiente	135936.7
Nesterov	106427.0	Nesterov	106426.2
ISTA	121963.8	ISTA	121813.0
FISTA	101970.9	FISTA	101965.9
Grad. Conjugado	112492.3	Grad. Conjugado	112492.3


Observa-se que, de modo geral, a utilização do passo exato resulta nos menores valores da função objetivo, indicando melhor desempenho em comparação com as escolhas de passo fixo. Entre as escolhas de passo fixo, nota-se que o valor $\lambda = 1.0$ foi o que apresentou melhor desempenho para todos os métodos analisados, produzindo sistematicamente os menores valores finais da função objetivo quando comparado aos passos 0.1 e 0.5. Já o passo 0.1 apresentou os piores resultados, o que está associado à menor velocidade de descida causada por um passo muito pequeno.

Além disso, pode-se observar que os métodos acelerados, como Nesterov e FISTA, obtêm valores menores da função objetivo em comparação com seus equivalentes não acelerados (Gradiente Descendente e ISTA, respectivamente), evidenciando o impacto positivo dos mecanismos de aceleração. Por fim, o método do Gradiente Conjugado apresenta valores finais bastante competitivos em todas as situações analisadas, inclusive

obtendo o menor valor no caso do passo fixo 0.1.

A Figura (3) apresenta a evolução do erro relativo da solução ao longo das iterações para os diferentes métodos considerados.

Figura 3: Erros de relativos de x^k



De forma geral, vemos que o comportamento dos gráficos são consistentes com aqueles apresentados anteriormente na análise da função objetivo. Métodos não acelerados, como o Gradiente Descendente e o ISTA, apresentam uma redução mais suave e estável do erro. Já os métodos acelerados, como Nesterov e FISTA, apresentam pequenas oscilações nas primeiras iterações. A escolha do tamanho do passo influencia diretamente a velocidade de redução do erro. E todos os métodos apresentam uma redução significativa do erro nas primeiras iterações, indicando que as soluções aproximam-se rapidamente da imagem original.

Por outro lado, o método do Gradiente Conjugado apresenta um comportamento distinto dos demais. Embora o erro inicial diminua rapidamente, observa-se posteriormente um aumento gradual do erro ao longo das iterações. Esse comportamento sugere que, apesar de reduzir inicialmente a distância em relação à solução desejada, o método passa a se afastar da imagem original nas iterações seguintes.

6.3.2 Análise custo/benefício em tempo de computação

Aqui são apresentados os resultados referentes ao tempo de computação dos métodos em função da escolha do tamanho do passo. Fixando o critério de convergência

$$\|x^k - x^*\| \leq 6 \times 10^{-2},$$

que corresponde aproximadamente ao menor erro observado nos experimentos, os gráficos da Figura (4) apresenta o tempo total de computação (em segundos) necessário para que cada método atingisse esse critério de convergência.

Figura 4: Caption




Tabela 2: Tempo e número de iterações por método

Passo	Gradiente Descendente			Nesterov			ISTA			FISTA			Gradiente Conjugados		
	TPI	I	TT	TPI	I	TT	TPI	I	TT	TPI	I	TT	TPI	I	TT
10^{-1}	0.0266	744	19.7982	0.0289	71	2.0546	0.0703	362	25.4411	0.0702	48	3.3707	-	-	-
$2,0 \times 10^{-1}$	0.0275	372	10.2166	0.0289	49	1.4144	0.0679	181	12.2854	0.0702	33	2.3171	-	-	-
$3,0 \times 10^{-1}$	0.0277	248	6.8733	0.0286	40	1.1454	0.0684	121	8.2731	0.0703	27	1.8978	-	-	-
$4,0 \times 10^{-1}$	0.0279	186	5.1930	0.0290	34	0.9851	0.0688	91	6.2644	0.0709	23	1.6296	-	-	-
$5,0 \times 10^{-1}$	0.0267	149	3.9750	0.0283	30	0.8475	0.0696	73	5.0809	0.0701	20	1.4017	-	-	-
$6,0 \times 10^{-1}$	0.0274	124	3.3994	0.0285	27	0.7704	0.0686	61	4.1820	0.0687	18	1.2361	-	-	-
$7,0 \times 10^{-1}$	0.0269	106	2.8495	0.0283	25	0.7065	0.0675	52	3.5091	0.0686	17	1.1657	-	-	-
$8,0 \times 10^{-1}$	0.0272	93	2.5290	0.0287	23	0.6591	0.0677	46	3.1136	0.0674	15	1.0117	-	-	-
$9,0 \times 10^{-1}$	0.0327	83	2.7178	0.0285	22	0.6266	0.0676	41	2.7698	0.0676	14	0.9463	-	-	-
10^0	0.0294	75	2.2020	0.0273	20	0.5460	0.0663	37	2.4531	0.0655	13	0.8515	-	-	-
Exato	0.0275	74	2.0343	0.0303	20	0.6066	0.0686	36	2.4700	0.0700	13	0.9106	0.0284	12	0.3403

A Tabela (2) mostra, para cada método e escolha de passo, o tempo por iteração (TPI),

o número de iterações necessárias para convergência (I) e o tempo total de computação (TT).

Observa-se inicialmente que o tempo por iteração permanece aproximadamente constante para cada método, independentemente do valor do passo utilizado. Isso indica que o custo computacional de cada iteração depende principalmente das operações realizadas em cada método, e não da escolha do passo.

Por outro lado, o tempo total de computação varia significativamente com a escolha do passo, pois depende diretamente do número de iterações necessárias para satisfazer o critério de convergência. De forma geral, observa-se que passos maiores resultam em menor número de iterações, reduzindo assim o tempo total necessário para a convergência.

Comparando os diferentes métodos, nota-se que os métodos acelerados, como Nesterov e FISTA, necessitam de um número significativamente menor de iterações para atingir o critério de convergência quando comparados com os métodos Gradiente Descendente e ISTA.

Além disso, o método do Gradiente Conjugado apresenta o menor tempo total de computação entre os métodos analisados, necessitando de apenas 12 iterações para atingir o critério de convergência.

6.3.3 Aplicações

Agora avaliaremos a qualidade das imagens reconstruídas. As imagens da Figura 5 mostram a imagem reconstruída para cada método considerando diferentes escolhas de passo.

Inicialmente, observa-se diferenças visuais podem ser observadas entre os métodos e escolhas de passo, principalmente em relação à presença de ruído residual e nitidez das bordas.

No caso do Gradiente Descendente, nota-se que a qualidade da reconstrução melhora conforme o valor do passo aumenta. Para passos menores, como 0.1, a imagem reconstruída ainda apresenta maior suavização e perda de detalhes. À medida que o passo aumenta, observa-se uma reconstrução mais nítida, com melhor recuperação das bordas. Resultados semelhantes podem ser observados para o método de Nesterov e o método ISTA.

Por outro lado, o método FISTA apresenta reconstruções visualmente mais próximas da imagem original, com melhor definição de bordas e menor presença de ruído em comparação com os métodos anteriores. Isso está de acordo com o comportamento observado nas análises anteriores, nas quais FISTA apresentou bom desempenho tanto na redução da função objetivo quanto no erro relativo.

Por fim, observa-se que a reconstrução obtida pelo Gradiente Conjugado apresenta maior presença de ruído residual quando comparada aos demais métodos. Esse comportamento pode ser explicado pelo fato de que esse método é particularmente eficiente para



Figura 5: Caption

problemas quadráticos, mas não é naturalmente adaptado para problemas com termos de regularização não diferenciáveis ou presença de ruído.

7 Discussão e Conclusões

Neste trabalho foram analisados diferentes métodos iterativos para a resolução de um problema de reconstrução de imagens degradadas por borramento e ruído. Em particular, foram considerados os métodos do Gradiente Descendente, Nesterov, ISTA, FISTA e Gradiente Conjugado, avaliando-se seu desempenho em termos de redução da função objetivo, erro relativo da solução, tempo de computação e qualidade visual das reconstruções obtidas.

A análise dos valores da função objetivo mostrou que todos os métodos considerados são capazes de reduzir significativamente o valor inicial da função ao longo das iterações. Entretanto, observou-se que métodos acelerados, como Nesterov e FISTA, tendem a alcançar valores menores da função objetivo mais rapidamente quando comparados às suas versões não aceleradas. Entre os métodos analisados, o FISTA apresentou consistentemente alguns dos melhores valores finais da função objetivo.

A análise do erro relativo em relação à imagem original mostrou comportamento semelhante, com rápida redução do erro nas primeiras iterações para todos os métodos. Contudo, métodos acelerados apresentaram pequenas oscilações próximas à solução, o que é um comportamento típico desses algoritmos devido ao mecanismo de aceleração utilizado. Ainda assim, esses métodos foram capazes de atingir baixos níveis de erro em um número reduzido de iterações.

Em relação ao tempo de computação, observou-se que o custo por iteração é aproximadamente constante para cada método, sendo o tempo total de execução fortemente influenciado pelo número de iterações necessárias para atingir o critério de convergência. Nesse contexto, métodos acelerados como Nesterov e FISTA apresentaram desempenho significativamente superior ao Gradiente Descendente e ao ISTA, enquanto o método do Gradiente Conjugado apresentou o menor tempo total de computação entre todos os métodos considerados.

Por fim, a análise visual das imagens reconstruídas indicou que todos os métodos foram capazes de recuperar a estrutura global da imagem original. Entretanto, diferenças podem ser observadas na presença de ruído residual e na nitidez das bordas. Em geral, métodos baseados em técnicas proximais e aceleração, como o FISTA, produziram reconstruções visualmente mais estáveis e com melhor qualidade na presença de ruído.

De forma geral, os resultados obtidos indicam que existe um compromisso entre custo computacional, velocidade de convergência e qualidade da solução reconstruída. Métodos acelerados apresentam vantagens importantes nesse contexto, sendo capazes de alcançar boas soluções em menos iterações e com menor tempo total de computação. Assim, para problemas de reconstrução de imagens com regularização e presença de ruído, métodos como o FISTA mostram-se particularmente adequados.

Referências