UNIVERSIDADE DE SÃO PAULO
INSTITUTO DE CIÊNCIAS MATEMÁTICAS E DE COMPUTAÇÃO
BACHARELADO EM MATEMÁTICA APLICADA E COMPUTAÇÃO CIENTÍFICA

VILENO CUNHA CAVALCANTE

INFLUÊNCIA DO USO DE BUSCA LINEAR EXATA NA CONVERGÊNCIA DE MÉTODOS ACELERADOS DE GRADIENTE PROXIMAL

SÃO CARLOS - SP
2025

VILENO CUNHA CAVALCANTE

INFLUÊNCIA DO USO DE BUSCA LINEAR EXATA NA CONVERGÊNCIA DE MÉTODOS ACELERADOS DE GRADIENTE PROXIMAL

Relatório parcial do Programa Unificado de Bolsas (PUB) apresentado a Pró-Reitoria de Pesquisa e Inovação (PRPI), como parte das exigências para a conclusão da Iniciação Científica em Influência do Uso de Busca Linear Exata na Convergência de Métodos Acelerados de Gradiente Proximal, sob orientação da Prof. Dr. Elias Salomão Helou Neto.

SÃO CARLOS - SP
2025

Sumário

1 Introdução **1**

2 Justificativa **3**

2.1 Tomografia computadorizada 3

2.2 Motivação para o estudo proposto 4

3 Materiais e Métodos **5**

4 Objetivos **6**

4.1 Objetivos gerais 6

4.2 Objetivos específicos 6

5 Método de Otimização **7**

5.1 Algoritmo FISTA 7

5.2 Estratégias usuais de escolha do tamanho de passo 7

5.3 Estratégia proposta: busca linear exata 8

6 Implementação e Experimentos Numéricos **8**

6.1 Descrição dos dados e configuração experimental 8

6.2 Métricas de avaliação 9

6.3 Resultados obtidos 9

6.3.1 Análise do ganho de velocidade de convergência 9

6.3.2 Análise custo/benefício em tempo de computação 10

6.3.3 Aplicações 11

7 Discussão e Conclusões **12**

Lista de Figuras

1 Evolução de $f(x)$ alongo das iterações para cada método 9
2 Erros de relativos 10
3 Caption 11

1 Introdução

Praticamente todos problemas em diversas áreas da ciência e da engenharia utilizam métodos matemáticos para serem modelados e resolvidos. Em particular, grande parte desses problemas pode ser formulados como a minimização de funções convexas e a esses problemas dar-se o nome de otimização. De maneira geral, um problema de otimização consiste em determinar os valores de um conjunto de variáveis de decisão que minimizam (ou maximizam) uma função objetivo, sujeita a restrições que modelam limitações físicas, econômicas ou operacionais do sistema em estudo.

Existem muitas classificações possíveis para um problema de otimização, que podem ser caracterizadas de acordo com o valor que suas variáveis de decisão podem assumir, e quanto à natureza de sua função objetivo e de suas restrições. Neste trabalho, abordamos os problemas de otimização não linear onde (aqui explica o que um problema de otimização não linear), mais especificamente problemas de otimização convexa composta da forma

$$\min_{x\in\mathbb{R}^n} F(x) = f(x) + g(x),$$

onde f é convexa diferenciável com gradiente Lipschitz-contínuo e g é convexa. Problemas como esse aparecem com frequência em matemática aplicada, aprendizado de máquina e processamento de sinais **?**. Um caso de amplo interesse é quando temos problemas de reconstrução de imagens através da minimização de funções com a seguinte forma

$$\min_{x\in\mathbb{R}^n} \frac{1}{2}\|Ax - b\|_2^2 + g(x), \tag{1}$$

onde $A \in \mathbb{R}^{m\times n}$, $b \in \mathbb{R}^m$ e $g : \mathbb{R}^n \to \mathbb{R}$ é convexa e prox-amigável. Por prox-amigável, queremos dizer que o operador proximal de λg, para $\lambda \in \mathbb{R}_+$, é calculável em um tempo de computação razoável. A definição do operador proximal $\mathrm{prox}_{\lambda g}(x)$ de λg em x é dado por

$$\mathrm{prox}_{\lambda g}(x) := \arg\min_{y\in\mathbb{R}^n} \frac{1}{2}\|y - x\|_2^2 + \lambda g(y). \tag{2}$$

Para essa classe de problemas, os métodos de gradiente proximal constituem uma abordagem eficiente e amplamente utilizada. Os métodos acelerados de gradiente proximal, inspirados na aceleração de Nesterov , alcançam a taxa ótima de convergência $\mathcal{O}(1/k^2)$ no caso convexo, superando a taxa $\mathcal{O}(1/k)$ dos métodos proximais clássicos. Entretanto, seu desempenho depende criticamente da escolha do tamanho de passo, usualmente determinado a partir da constante de Lipschitz do gradiente de f, que nem sempre é conhecida ou estimada de forma adequada.

Uma alternativa é empregar estratégias adaptativas, como a busca linear. Em particular, a busca linear exata determina o tamanho de passo ótimo ao longo da direção escolhida, podendo potencialmente melhorar o desempenho prático do método. No en-

tanto, sua interação com o mecanismo de aceleração ainda demanda análise cuidadosa, pois pode afetar propriedades como estabilidade e taxa de convergência.

Neste trabalho, investigamos a influência do uso de busca linear exata na convergência de métodos acelerados de gradiente proximal. Analisamos sob quais condições a estratégia preserva as garantias teóricas conhecidas, se pode melhorar o comportamento prático do algoritmo e como impacta a dinâmica iterativa do processo de otimização. Resultados teóricos são acompanhados de experimentos numéricos que ilustram o efeito da busca linear exata no desempenho do método.

2 Justificativa

Em problemas de reconstrução de imagens, o número n de variáveis corresponde ao número de *pixels* da imagem e, portanto, pode ser extremamente grande, frequentemente da ordem de centenas de milhares ou até mesmo milhões. Problemas da forma (1) surgem em diversas aplicações de processamento de imagens, como tomografia computadorizada **????**, remoção de ruído em imagens **???** e restauração de imagens desfocadas e degradadas por ruído **???**.

De maneira geral, esse tipo de modelo aparece naturalmente no contexto da regularização variacional de problemas inversos lineares mal condicionados **?**. Em tomografia computadorizada, por exemplo, o problema de reconstrução pode ser formulado como um sistema linear de grande dimensão, frequentemente envolvendo matrizes muito grandes e esparsas.

2.1 Tomografia computadorizada

Deixando de lado o desenvolvimento de detalhes técnicos da física subjacente, a situação em um tomógrafo leva a um modelo baseado na transformada de Radon **???** $\mathcal{R}[f]$ de $f : \mathbb{R}^2 \to \mathbb{R}$, definida através de

$$\mathcal{R}[f](\theta, t) := \int_{\mathbb{R}} f\left(t \begin{pmatrix} \cos\theta \\ \sin\theta \end{pmatrix} + s \begin{pmatrix} -\sin\theta \\ \cos\theta \end{pmatrix}\right) ds.$$

Veja a Figura 1 para uma ilustração.

A incógnita é a função f, ao passo que os dados obtidos são os valores da transformada de Radon $\mathcal{R}[f]$. Uma vez que o tempo de coleta de dados é limitado e que na prática a função solução é buscada em um espaço de dimensão finita, o problema pode ser reduzido à solução (aproximada) de um sistema de equações lineares

$$Rx \approx r,$$

onde $R \in \mathbb{R}^{m \times n}$ é uma matriz obtida a partir da discretização da transformada de Radon, que depende da base utilizada para descrever o espaço de funções e das condições geométricas de aquisição, $x \in \mathbb{R}^n$ é o vetor desconhecido de coeficientes da combinação linear de elementos da base que resulta na solução do problema (i.e., a solução é

$$f = x_1 f_1 + x_2 f_2 + \cdots + x_n f_n,$$

onde $\{f_1, f_2, \ldots, f_n\}$ é a base para o espaço de funções onde a solução é buscada) e r é o vetor de dados coletados (sempre aproximado pois há erros sistemáticos de modelagem e ruído na aquisição dos dados).

2.2 Motivação para o estudo proposto

Uma vez que, graças à natureza da transformada de Radon, a matriz R sempre é mal condicionada e o lado direito r inevitavelmente contém ruído, a solução aproximada deve ser estabilizada através do uso de um termo de suavização, de modo que o modelo a ser resolvido possua a forma

$$\min_x \; f(Rx, r) + \gamma g(x),$$

onde $f : \mathbb{R}^m \times \mathbb{R}^m \to \mathbb{R}$ é uma função que força a proximidade entre Rx e r, $g : \mathbb{R}^n \to \mathbb{R}$ é uma função que força a suavidade da imagem resultante e $\gamma \in \mathbb{R}_+$ é um parâmetro que controla a suavidade imposta na solução do problema. Algoritmos de ε-subgradientes foram utilizados com sucesso em **?** e algoritmos acelerados de primeira ordem em **??** para resolver modelos úteis da forma acima. Nenhum dos trabalhos mencionados leva em consideração a forma específica de quadrados mínimos regularizados que possui (1), portanto, esperamos que as técnicas a serem estudadas no presente projeto sejam ainda mais bem sucedidas nesta aplicação.

3 Materiais e Métodos

A execução do presente projeto utilizará computadores comuns e *software* de código livre cuja disponibilidade é ampla e que são facilmente acessíveis. Nos dias de hoje, rotinas numéricas eficientes são facilmente utilizadas através de suas interfaces de programação para linguagens de alto nível, mesmo quando tais rotinas são implementadas em linguagens mais ineficientes. Em particular, a linguagem Python reúne numerosas bibliotecas úteis no nosso contexto e, por este motivo, escolhemos esta linguagem para a execução da parte computacional do nosso projeto.

Por exemplo, para a computação de produtos matriz-vetor da forma Ax ou $A^T y$, onde A é a discretização da Transformada de Radon, temos as bibliotecas ASTRA ou a desenvolvida pelo orientador [1], ambas com suporte a GPU e com interfaces para Python. Para outras modalidades de reconstrução como recuperação de imagens desfocadas, podemos usar as ferramentas implementadas eficientemente no pacote `scipy.signal`.

Para a parcela de regularização, iremos utilizar uma opções que é apropriada para o problema de reconstrução de imagens:

$$g(x) = \gamma \|Hx\|_1,$$

onde $\gamma \geq 0$ é o parâmetro de regularização e H é uma transformada *wavelet* (que é ortonormal, auto-adjunta e computável eficientemente). Para esta regularização, o operador proximal de λg tem a forma fechada

$$\mathrm{prox}_{\lambda g}(x) = H^T S_{\gamma\lambda}(Hx),$$

onde $S_{\lambda\gamma}$ é o operador de *soft-thresholding*, dado por

$$(S_\alpha(y))_i = \begin{cases} y_i + \alpha, & \text{se } y_i \leq -\alpha, \\ 0, & \text{se } y_i \in (-\alpha, \alpha), \\ y_i - \alpha, & \text{se } y_i \geq \alpha. \end{cases}$$

[1] `https://github.com/elias-helou/ray_tracing`

4 Objetivos

4.1 Objetivos gerais

O objetivo do seguinte projeto de iniciação científica é estudar o que ocorre quando, para o caso especial (1), o tamanho de passo de máxima descida do método de gradiente proximal acelerado conhecido como FISTA **??** é escolhido através de busca direcional exata.

4.2 Objetivos específicos

- Analisar experimentalmente o ganho de velocidade de convergência em número de iterações com o uso do passo exato com regularização baseada na transformada *wavelet*.
- Avaliar o ganho de custo/benefício em tempo de computação entre o passo fixo e passo exato com regularização baseada na transformada *wavelet*.
- Aplicar o método para o caso de reconstrução de imagens com regularização baseada no transformada *wavelet*.

5 Método de Otimização

Ao resolver numericamente um problema de otimização matemática, o algoritmo a ser utilizado deve ser escolhido baseado em considerações acerca do problema em mãos. Durante o processo de escolha de tal algoritmo numérico, devemos levar em conta a categoria de problema sendo resolvido (linear, cônico de segunda ordem, convexo, suave, inteiro, contínuo, etc.) e da informação disponível, também conhecida como oráculo, a cada passo do método (valor funcional, gradientes, hessianas, funções substitutas, minimizadores de relaxações, etc.). Outros fatores importantes também influenciam a escolha do método, tais como ambiente e plataforma computacional, tempo de computação disponível, precisão numérica necessária ou desejada, dimensões do problema (número de variáveis e tamanho do conjunto de dados), dentre outros.

5.1 Algoritmo FISTA

Considere o problema

$$\min_{x \in \mathbb{R}^n} \; f(x) + g(x), \tag{3}$$

onde $f : \mathbb{R}^n \to \mathbb{R}$ é convexa e diferenciável e $g : \mathbb{R}^n \to \mathbb{R}$ é convexa.

Ademais, supomos que o gradiente de f é Lipschitz. Isto é, existe $L_f \geq 0$ tal que

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L_f \|x - y\|_2$$

e que o operador proximal de g, como definido em (2), pode ser calculado com relativa facilidade.

Para esta categoria de problemas, quando o número n de variáveis é muito grande, um algoritmo popular para aplicação é o FISTA **??**:

$$\begin{aligned}
y^{(k)} &= \operatorname{prox}_{\lambda_k g}\left(x^{(k)} - \lambda_k \nabla f(x^{(k)})\right) \\
t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2} \\
x^{(k+1)} &= y^{(k)} + \frac{t_k - 1}{t_{k+1}}\left(y^{(k)} - y^{(k-1)}\right).
\end{aligned}$$

5.2 Estratégias usuais de escolha do tamanho de passo

Na formulação acima, o passo λ_k pode ser mantido fixo, desde que suficientemente pequeno, mas precisamente $\frac{1}{L}$, em que $L > 0$ é a constante de Lipschitz de $\nabla f(x)$, ou determinado através de uma busca direcional acoplada a um critério de descida suficiente.

5.3 Estratégia proposta: busca linear exata

Observe que FISTA foi desenvolvido para o caso mais geral (3), onde a busca direcional exata é impossível. Para o caso em que f é uma função quadrática da forma

$$f(x) = \frac{1}{2}x^T Ax - c^T x,$$

entretanto, o tamanho de passo que minimiza a função a partir de $x^{(k)}$ ao longo de uma direção de busca $d^{(k)} = \nabla f(x^{(k)})$ pode ser calculado com esforço computacional relativamente baixo através da fórmula

$$\lambda_k = \frac{(d^{(k)})^T d^{(k)}}{(d^{(k)})^T A d^{(k)}}$$

Em métodos para minimizar apenas a função quadrática f, o cálculo de $Ad^{(k)}$ pode ser reaproveitado posteriormente ou vir de quantidades calculadas previamente.

6 Implementação e Experimentos Numéricos

6.1 Descrição dos dados e configuração experimental

Os experimentos computacionais foram realizados em um computador Intel® Core™ i7-11800H - 8GB de RAM com frequência 2.30GHz com sistema operacional Windows 11 Pro versão 25H2. O modelo foi implementado em linguagem de programação Python versão 3.12.4 no ambiente de desenvolvimento Visual Studio Code versão 1.97.2. Foram utilizadas as bibliotecas `NumPy`, para operações matriciais e cálculos numéricos. Para a modalidade de reconstrução de imagem desfocadas, as operações de *convolução* A e sua adjunta A^T (*correlação*) foram ambas implementadas utilizando a biblioteca `scipy.signal`.

Neste experimento, usamos uma imagem bidimensional de dimensão 512×512 pixels monocromática de um câmera, normalizada no intervalo padrão da biblioteca. Esta imagem está disponível na biblioteca `skimage-image`. E por fim; foi utilizado a `matplotlib`, para visualização das imagens e análise gráfica do comportamento dos métodos iterativos.

Como uma boa prática, antes da execução dos métodos iterativos, foi realizada uma verificação numérica da propriedade de adjointidade entre os operadores A e A^T, verificando se a relação

$$\langle Ax, y\rangle = \langle x, A^T y\rangle$$

é satisfeita para vetores aleatórios x e y. Os resultados numéricos confirmaram a consistência da implementação dos operadores.

6.2 Métricas de avaliação

A qualidade da reconstrução e o desempenho dos métodos iterativos foram avaliados a partir de diferentes métricas numéricas e visuais.

- O valor da função objetivo f foi monitorado ao longo das iterações para cada método.
- Além disso, foi considerado os erros relativos da imagem reconstruída e da função objetivo
$$r_x^k = \frac{|x^k - x^*|}{|x^*|} \quad \text{e} \quad r_f^k = \frac{|f(x^k) - f^*|}{|f^*|}$$
respectivamente, onde x^* denota a imagem original e f^* o melhor valor de f obtido pelo método dos gradientes conjugados.

6.3 Resultados obtidos

Analisaremos agora os resultados obtidos nos experimentos.

6.3.1 Análise do ganho de velocidade de convergência

A Figura 1 mostra o gráfico comportamento de f alongo de 500 iterações.

Figura 1: Evolução de $f(x)$ alongo das iterações para cada método

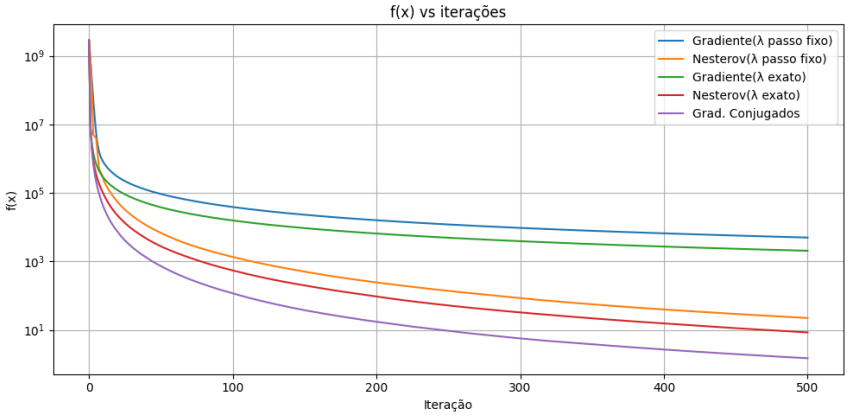

Aqui um avaliação/analise do gráfico 1

Os gráficos 2a e 2b apresenta os erros relativos da imagem reconstruída e da função objetivo respectivamente.

Figura 2: Erros de relativos

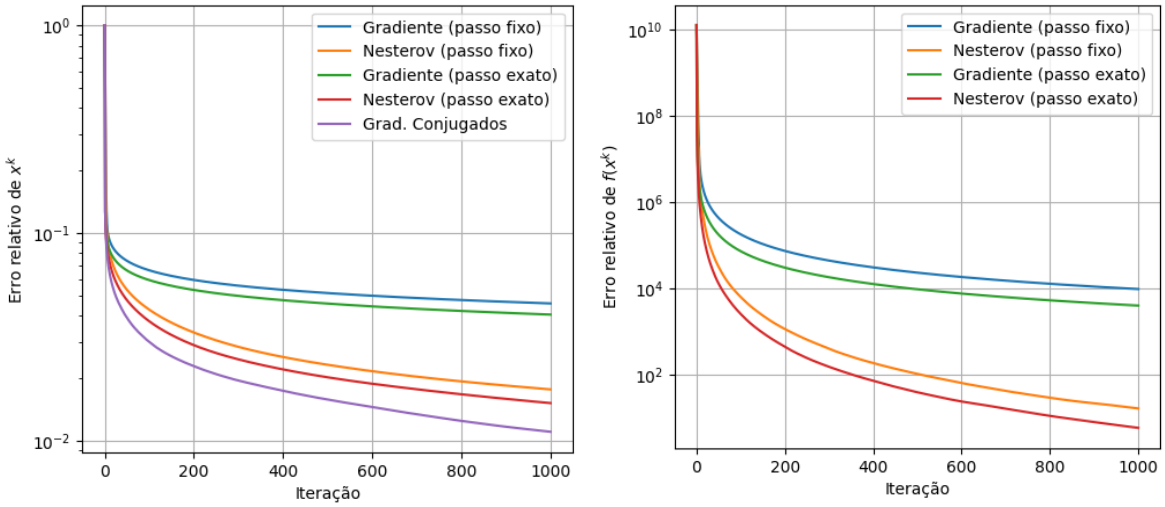

(a) (b)

Aqui um avaliação/analise dos gráficos 2a e 2b

6.3.2 Análise custo/benefício em tempo de computação

Definindo um critério fixo de convergência $||x^k - x^*|| \leq 10^{-1}$, a Tabela 1 mostrar o numero de iterações que cada método precisou até convergir.

Tabela 1: Número de iterações até convergir com diferentes escolhas do passo

	Gradiente Descendente	Nesterov	Gradiente Conjugados
Escolha de passo	**Iterações até convergir**	**Iterações até convergir**	**Iterações até convergir**
Passo fixo	597	61	-
Passo exato	295	42	24

Aqui um avaliação/analise da Tabela 1

Aqui mostraremos os resultados em relação ao tempo de computação dos método a partir da escolha passo. O gráfico 3 apresenta a evolução de $f(x^k)$ de acordo com o tempo de execução em segundos.

Figura 3: Caption

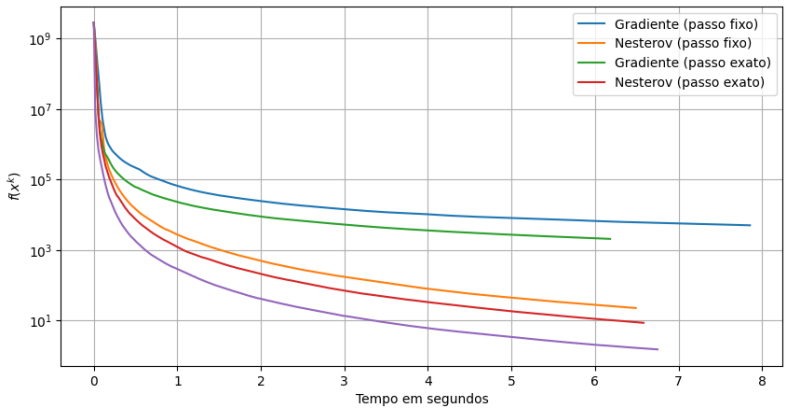

Aqui um avaliação/analise do gráfico 3

A Tabela 2 mostra o Custo computacional dos métodos.

Tabela 2: Custo computacional dos métodos com diferentes escolhas do passo

	Gradiente Descendente			Nesterov		
Método	**Tempo por iteração (s)**	**Iterações**	**Tempo total (s)**	**Tempo por iteração (s)**	**Iterações**	**Tempo total (s)**
Passo fixo	1.2	1240	1.49	1.2	1240	1.49
Passo exato	6.8	430	2.92	6.8	430	2.92

Do lado esquerdo são apresentados os custos do método dos Gradientes Descendentes e do lado esquerdo do Nesterov. Podemos observar que foram destacados os o tempo por iteração, a quantidade de iterações e o tempo total gasto pelo método para cada escolha passo.

6.3.3 Aplicações

Agora avaliaremos a qualidade das imagens reconstruídas. As Figuras **??**-**??** mostra a imagem reconstruída para cada método com diferentes escolhas de passos.

7 Discussão e Conclusões

Referências